Démonstrateur d'attaques contre un ML-NIDS

État de l'art et premier prototype réseau

Projet VAP SSR 2026–2027

Réunion avec Grégory Blanc

27 octobre 2026

Avancées depuis la réunion du 6 octobre

- **État de l'art rédigé** sur les attaques contre les ML-NIDS.
- **Premier site développé** pour construire une topologie réseau par glisser-déposer, dans l'esprit de Packet Tracer.

À faire ensuite

Choisir les modèles et les attaques, puis les intégrer au démonstrateur.

État de l'art : apport des trois nouveaux papiers

Das montrait déjà l'empoisonnement :
un attaquant modifie les étiquettes d'entraînement pour dégrader le détecteur.

- **Alhussien : piéger une source de données externe.**
  Contrairement au scénario de Das, l'attaquant n'a pas besoin de compromettre le système interne de la victime.
- **PCAP-Backdoor : piéger les paquets, garder les bonnes étiquettes.**
  Ajouter un motif dans des captures de trafic bénin, toujours étiquetées « bénin ». Le modèle apprend à associer ce motif au trafic normal.
- **Ma : confier l'entraînement à un prestataire malveillant.**
  Le prestataire insère un motif dans les caractéristiques d'exemples d'entraînement et les réétiquette « bénin ». L'étude ne construit pas ce motif en paquets réels.

Point commun aux deux backdoors : faire passer les attaques portant le motif, tout en restant performant sans lui.

Le site : construire une topologie réseau

Une interface web inspirée de Packet Tracer.

- Ajouter et déplacer des équipements par glisser-déposer.
- Relier les équipements aux switches avec l'outil câble.
- Modifier les paramètres réseau dans le panneau de propriétés.
- Vérifier la cohérence de la topologie avant le déploiement.

Exécution et observation : fonctions implémentées

Le code du prototype comprend :

- Le déploiement de la topologie sous forme de conteneurs et de réseaux Docker.
- Un terminal pour les PC et les serveurs démarrés.
- La capture des paquets sur une interface d'équipement reliée à un switch.
- L'affichage des paquets, des filtres et un export PCAP.

La détection ML et l'exécution des attaques restent à intégrer.

Démonstration du prototype

Intégration du ML-NIDS : travail restant

1. **Choisir et reproduire une référence :** fixer le modèle, l'extracteur et les données de départ.
2. **Relier la sonde au détecteur :** transformer le trafic capturé en caractéristiques et obtenir un score ou une décision.
3. **Intégrer une attaque compatible :** préciser les accès nécessaires et les limites de modification du trafic.
4. **Afficher la comparaison :** trafic de référence, trafic transformé et résultat de détection.

Premier objectif proposé : une expérience reproductible de bout en bout sur une topologie simple.

Questions pour Grégory Blanc

1. **Comparaison avant / après :** quelles informations afficher pour rendre l'effet de l'attaque facile à comprendre ?
2. **Représentation :** privilégier une vue du réseau, une chronologie des échanges ou des graphiques de résultats ?
3. **Déroulement :** montrer l'attaque en direct, étape par étape, ou présenter un bilan comparatif à la fin ?
4. **Message pédagogique :** que doit retenir l'utilisateur après avoir vu une démonstration ?