Démonstrateur d'attaques contre un ML-NIDS

État de l'art et premier prototype réseau

Projet VAP SSR 2026–2027

Réunion avec Grégory Blanc

27 octobre 2026

Avancées depuis la réunion du 6 octobre

- **État de l'art rédigé** sur les attaques contre les ML-NIDS.
- **Premier site développé** pour construire une topologie réseau par glisser-déposer, dans l'esprit de Packet Tracer.

À faire ensuite

Choisir les modèles et les attaques, puis les intégrer au démonstrateur.

État de l'art : pourquoi trois nouveaux papiers ?

Au 6 octobre, l'empoisonnement reposait sur Venkatesan et Das :

- l'objectif était seulement de **dégrader** le détecteur (plus d'erreurs) ;
- l'attaquant était **déjà à l'intérieur** (accès aux données, contrôleur SDN compromis) ;
- les attaques portaient sur des **tableaux de caractéristiques**, pas sur des paquets.

Trois manques, trois papiers ajoutés :

1. Un attaquant **qui n'entre pas** chez la victime → **Alhussien**.
2. Les **portes dérobées** : le modèle semble bon, mais laisse passer le trafic qui porte un motif secret → **PCAP-Backdoor** et **Ma**.
3. Une attaque construite sur de **vrais paquets (PCAP)**, comme ceux capturés par notre prototype → **PCAP-Backdoor**.

État de l'art : ce que chaque nouveau papier apporte

	Qui est l'attaquant ?	Ce qu'il fait	Pourquoi on l'a retenu
Alhussien (2023)	Il pollue une **base de données publique** que la victime utilise pour entraîner son détecteur.	Il modifie 5 % de cette base. La détection des attaques passe de 79 % à 47 %.	Scénario **réaliste** : pas besoin de pirater la victime. Défense simple : plus de données internes.
PCAP-Backdoor (2026)	Il peut ajouter du trafic dans les **captures d'entraînement**.	Il glisse un motif dans du trafic normal, **sans changer les étiquettes**. Ses attaques avec ce motif sont ensuite classées « bénin ».	Travaille sur des **fichiers PCAP**, comme notre capture : le papier le plus proche du démonstrateur.
Ma (2025)	Le **prestataire** à qui la victime confie l'entraînement.	Il marque 0,1 % des exemples avec un motif et les étiquette « bénin ». Plus de 97 % des attaques marquées passent.	Montre qu'un **test classique ne suffit pas** (moins de 3 % de perte) et propose une **défense**.

À retenir : une porte dérobée ne se voit pas aux tests normaux, seulement avec le motif.

Le site : construire une topologie réseau

Une interface web inspirée de Packet Tracer.

- Ajouter et déplacer des équipements par glisser-déposer.
- Relier les équipements aux switches avec l'outil câble.
- Modifier les paramètres réseau dans le panneau de propriétés.
- Vérifier la cohérence de la topologie avant le déploiement.

Exécution et observation : fonctions implémentées

Le code du prototype comprend :

- Le déploiement de la topologie sous forme de conteneurs et de réseaux Docker.
- Un terminal pour les PC et les serveurs démarrés.
- La capture des paquets sur une interface d'équipement reliée à un switch.
- L'affichage des paquets, des filtres et un export PCAP.

La détection ML et l'exécution des attaques restent à intégrer.

Démonstration du prototype

Intégration du ML-NIDS : travail restant

1. **Choisir et reproduire une référence :** fixer le modèle, l'extracteur et les données de départ.
2. **Relier la sonde au détecteur :** transformer le trafic capturé en caractéristiques et obtenir un score ou une décision.
3. **Intégrer une attaque compatible :** préciser les accès nécessaires et les limites de modification du trafic.
4. **Afficher la comparaison :** trafic de référence, trafic transformé et résultat de détection.

Premier objectif proposé : une expérience reproductible de bout en bout sur une topologie simple.

Questions pour Grégory Blanc

1. **Comparaison avant / après :** quelles informations afficher pour rendre l'effet de l'attaque facile à comprendre ?
2. **Représentation :** privilégier une vue du réseau, une chronologie des échanges ou des graphiques de résultats ?
3. **Déroulement :** montrer l'attaque en direct, étape par étape, ou présenter un bilan comparatif à la fin ?
4. **Message pédagogique :** que doit retenir l'utilisateur après avoir vu une démonstration ?